

Classificação de Elementos Transponíveis

Alec C. Aoki (15436800), Matheus V. Fernandes (14615993), Pedro A. F. Paffaro (15483380)

Instituto de Ciências Matemáticas e de Computação – Universidade de São Paulo (USP)

alec.aoki@usp.br, matheusvfernandes@usp.br, pedroafpaffaro@usp.br

Abstract. *This study aims to implement an automated pipeline for the assembly and classification of Transposable Elements (TEs) from the *Z. mays* genome. Annotation files (.gff3) and genomic sequences (.fasta) were integrated to extract the regions corresponding to six TE classes. The obtained sequences were processed by the MathFeature tool to extract structural and compositional features. The resulting set was used in classification experiments with the aim of automatically distinguishing TE classes.*

Resumo. *Este estudo busca implementar um pipeline automatizado para a montagem e classificação de Elementos Transponíveis (TEs) do genoma de *Z. mays*. Foram integrados arquivos de anotação (.gff3) e sequências genômicas (.fasta) para extrair as regiões correspondentes a seis classes de TEs. As sequências obtidas foram processadas pela ferramenta MathFeature para extração de características estruturais e composicionais. O conjunto resultante foi utilizado em experimentos de classificação com o objetivo de distinguir as classes de TEs de forma automatizada.*

1. Introdução

Elementos Transponíveis (TEs) são sequências de DNA capazes de se moverem dentro do genoma, podendo causar mutações, reorganizações estruturais e influenciar a expressão gênica. Essas sequências têm sido reconhecidas como componentes fundamentais da evolução genômica, especialmente em organismos eucarióticos, podendo representar uma fração expressiva do genoma, ultrapassando 80% de seu tamanho total.

Neste trabalho, propõe-se um pipeline completo para a montagem, pré-processamento e classificação de Elementos Transponíveis de *Z. mays*. Primeiramente, foram obtidos e integrados os arquivos de anotação (.gff3) e sequências genômicas (.fasta) para extração das sequências correspondentes aos TEs. Em seguida, as sequências foram processadas com a ferramenta *MathFeature* para a extração de características baseadas em descritores matemáticos, utilizando múltiplos descritores que fornecem medidas estruturais e composicionais das sequências. Por fim, os vetores de características foram utilizados para o treinamento e avaliação de um modelo de classificação.

O objetivo geral deste estudo é investigar o potencial de descritores matemáticos na representação de TEs e avaliar a capacidade de modelos supervisionados em distinguir diferentes classes de elementos transponíveis, contribuindo para o desenvolvimento de abordagens automatizadas e reproduzíveis na análise de genomas eucarióticos.

2. Metodologia

2.1. Montagem dos Dados

Para a construção do conjunto de dados de Elementos Transponíveis (TEs), foram utilizados os arquivos disponibilizados no Atlas dos Elementos Transponíveis em Plantas (APTE) referentes ao genoma de *Z. mays*. Foram baixados seis arquivos no formato .gff3, correspondentes às classes Helitron, LINE, LTR, MITE, SINE e TIR. Esses arquivos possuem informações para o mapeamento das TEs nos arquivos que contêm os cromossomos da planta *Z. mays*.

Em seguida, foi realizado o processamento das anotações contidas nos arquivos GFF3 com o objetivo de recuperar apenas as entradas localizadas na fita positiva (“Strand = +”). De cada linha foram extraídos: o cromossomo (Chr) e as posições de início e fim (Start e End) de cada TE.

Posteriormente, os genomas de referência dos cromossomos de *Z. mays* foram obtidos no formato .fasta a partir do NCBI Datasets. Os arquivos FASTA e GFF3 foram integrados por meio de um script em Python desenvolvido com auxílio da biblioteca BioPython, responsável por mapear as posições genômicas e extrair as respectivas sequências de TEs.

O processo de montagem foi automatizado e seu pipeline realiza as seguintes etapas principais:

- Cada arquivo .gff3 é lido e seus TEs são agrupados em um dicionário Python no formato cromossomo: [(início, fim, classe), ...].
- As chaves do dicionário são ordenadas numericamente (1, 2, 3, ...) e alfabeticamente para manter a coerência com os nomes dos arquivos FASTA.
- Para cada cromossomo, o script acessa o arquivo FASTA correspondente extraindo as subsequências delimitadas pelos valores de Start e End, e as associa à classe TE de origem.
- Ao final, são gerados dois arquivos: um arquivo CSV contendo as colunas Cromossomo, Sequência_TE e Classe e um arquivo com as mesmas sequências em formato FASTA padronizado que será utilizado para extração das características.

Esse processo garantiu a reprodutibilidade e automação da montagem do conjunto de dados, permitindo a extração precisa e sistemática das sequências genômicas de TEs. O resultado serviu como base para as etapas posteriores de pré-processamento e extração de características, realizadas pelo software MathFeature.

2.2. Filtragem dos Dados

O conjunto de dados bruto resultante das operações anteriores resultou em cerca de 338 mil sequências, ou seja, relativamente grande, com vários pontos sendo catalogados como outliers, conforme os gráficos a seguir.

Visando facilitar a extração das características e remover ruído, como TEs fragmentados, degenerados, ou ainda artefatos de montagem do genoma, implementamos filtros levando em conta o contexto biológico de cada classe, principalmente no que concerne ao comprimento esperado de cada tipo de sequência, conforme descrito em [Feng 2003] [Li et al. 2024] [Mhiri et al. 2022] [Stitzer et al. 2021].




Figure 1. Distribuição de classes original




Figure 2. Distribuição de tamanhos original




Figure 3. Boxplot de tamanho por classes original




Figure 4. Distribuição de %GC original

Os filtros e a quantidade de sequências removidas do conjunto de dados original por cada filtro está a seguir, em ordem de execução:

- Sequências duplicadas: 24219 sequências removidas;
- Sequências com caracteres inválidos (diferentes de A, C, T, G, N): 123 sequências removidas;
- Sequências muito curtas (menos de 30 pares de bases): 1329 sequências removidas;
- Sequências com tamanho de um intervalo restritivo, por classe: 157738 sequências removidas;
 - LTR: 1000 a 15000 pares de bases;
 - LINE: 1500 a 80000 pares de bases;
 - SINE: 50 a 600 pares de bases;
 - TIR: 300 a 10000 pares de bases;
 - MITE: 50 a 800 pares de bases;
 - Helitron: 500 a 200000 pares de bases.
- Sequências com mais de 0.01% de N: 644 sequências removidas
- Sequências com %GC fora do intervalo de 35 a 60 %, por classe: 19265 sequências removidas.

Ao todo foram removidas 202826 sequências (59.9% do conjunto de dados original).




Figure 5. Distribuição de classes limpo




Figure 6. Distribuição de tamanhos limpo




Figure 7. Boxplot de tamanho por classes limpo




Figure 8. Distribuição de %GC limpo

Após otimização do modelo, questionamos se esses filtros não estariam excessivamente restritivos, dado o grande número de sequências removidas. Testamos, portanto, uma abordagem mais permissiva com intervalos expandidos tanto no comprimento quanto na %GC. Nesta abordagem mais permissiva foram removidas 60045 sequências (17.7% do conjunto de dados original), no entanto o modelo perdeu acurácia no geral, indicando que a remoção de ruído foi eficiente.

2.3. Extração de Características

Após a montagem do conjunto de dados, as sequências de Elementos Transponíveis foram submetidas à extração de características. O comprimento das sequências foi extraído diretamente, e todas as outras características foram extraídas utilizando a ferramenta *MathFeature*, sendo:

- Composição de ácido nucleico (NAC);
- Composição de di-nucleotídeos (DNC);
- Composição de tri-nucleotídeos (TNC);
- Características codificantes (ORF);
- Pontuação de Fickett;
- Entropia de Shannon (de $k = 1$ a $k = 5$);
- Composição nucleotídica pseudo k-tupla;
- Composição nucleotídica pseudo k-tripla.

Ainda tomando em consideração [Feng 2003] [Li et al. 2024] [Mhiri et al. 2022] [Stitzer et al. 2021], essas características foram selecionadas considerando que LTRs têm sequências repetidas nas pontas e partes codificantes (justificando NAC, DNC, TNC e ORF), além de ter uma entropia média para alta (medida pela Entropia de Shannon).

LINEs também são longos, mas não têm pontas repetidas, e apenas algumas partes codificantes. SINEs são curtos e não codificantes, com entropia baixa. TIRs têm comprimento médio, com sequências invertidas nas pontas e podendo ou não terem partes codificantes. MITEs também são curtos e não-codificantes, mas altamente repetitivos e com extremidades invertidas, tendo baixa entropia. Helitrons têm tamanho variável, sendo difícil definir algo que o diferencie claramente pois podem ou não ter áreas codificantes, e não há nenhuma sequência interna com um padrão expressivo.

2.4. Pré-Processamento dos Dados

Primeiramente, os identificadores de cromossomos foram convertidos de strings para inteiros, padronizando o formato das variáveis. Em seguida, isolaram-se as colunas numéricas e o rótulo “class”, descartando-se campos irrelevantes como hashes de sequência. Para evitar redundâncias e ruídos, removeram-se colunas com valor constante e as duplicadas. Colunas contendo dados ausentes em mais de 10% das amostras também foram descartadas, e os demais valores faltantes foram preenchidos com a mediana de cada feature.

Além disso, features com correlação superior a 0,95 foram consideradas altamente redundantes, mantendo-se apenas uma representante de cada grupo correlacionado. Por fim, aplicou-se uma seleção supervisionada de features utilizando o método *SelectKBest* com o critério de informação mútua, de modo que as 30 variáveis com maior relevância informacional foram selecionadas para compor o conjunto final de entrada do modelo.

2.5. Modelo de aprendizado

Para a tarefa de classificação, adotou-se o modelo *Random Forest*, devido a sua robustez a ruídos, capacidade de lidar com muitos atributos, ajuste relativamente simples de hiperparâmetros e interpretação. Outros modelos foram testados junto de técnicas de *oversampling*, mas a *Random Forest* foi a que produziu melhores resultados. O *Random Forest* é um método de aprendizado de conjunto baseado em múltiplas árvores de decisão, sendo cada árvore treinada a partir de amostras e subconjuntos aleatórios de atributos. As previsões individuais são combinadas, resultando em uma decisão final mais estável e precisa do que a obtida por uma única árvore isolada.

2.6. Ajuste de hiperparâmetros

O ajuste dos hiperparâmetros foi realizado empiricamente, buscando maximizar acurácia e precisão, minimizar o overfitting e lidar com o desbalanceamento de classes.

Table 1. Hiperparâmetros finais do Random Forest

Hiperparâmetros
<code>n_estimators = 600, max_depth = 12</code>
<code>min_samples_split = 3, min_samples_leaf = 2</code>
<code>random_state = 42, n_jobs=-1</code>

2.7. Métricas de avaliação

Foram considerados três métricas para avaliar os modelos: sua acurácia (`accuracy_score`); a área abaixo da curva (Area Under the Curve, ou AUC) Precisão-Revocação de cada classe, bem como a média macro desses valores (PR-AUC macro); a área abaixo da curva de Característica de Operação Relativa de cada classe, assim como a média macro desses resultados (ROC-AUC macro); a Matriz de Confusão normalizada da classificação do conjunto de teste, obtida através do método `confusion_matrix` do `scikit-learn`.

Para avaliar as features utilizadas no classificador, foi utilizado o atributo `feature_importances_`, do `RandomForestClassifier`, o qual permite recuperar as importâncias Gini normalizadas das features no modelo treinado. Além disso, gerou-se a matriz de correlação entre as dez principais características através do método `.corr()` da biblioteca `pandas`, de modo a visualizar a dependência entre as features mais importantes.

3. Experimentos

3.1. Configuração experimental


Os dados foram divididos em conjuntos de treino e teste na proporção de 70% e 30%, respectivamente, de forma estratificada (preservando a proporção original entre as classes), e utilizando uma semente aleatória fixa (`random_state = 42`) para garantir a reprodutibilidade dos resultados.


3.2. Desempenho do modelo

Após treinar o modelo, obteve-se o seguinte desempenho em termos de acurácia, PR-AUC e ROC-AUC:

Table 2. Desempenho do modelo

Conjunto	Acurácia	PR-AUC macro	ROC-AUC macro
Treino	0.8247	0.7809	0.9339
Teste	0.8183	0.4951	0.8718






3.3. Matriz de confusão

Em relação a como cada TE foi classificado no conjunto de teste, tem-se:

Figure 10. Matriz de confusão - Teste



3.4. Features utilizadas

Verificando-se a importância normalizada de cada uma das 30 features utilizadas e a correlação entre as dez mais importantes na classificação do modelo, tem-se:

Figure 11. Importância das features na classificação





Figure 12. Correlação entre as principais features



4. Discussões

4.1. Modelo construído

Em um primeiro momento, a Tabela 2 sugere um classificador excelente, uma vez que, no conjunto de teste, a acurácia do modelo é superior a 80% e a média ROC-AUC macro aproxima-se de 90%, com leve overfitting. Contudo, é importante observar que essas métricas não são ideais para avaliar modelos em tarefas com classes desbalanceadas, como é o caso desta classificação. A acurácia mede a proporção de previsões corretas e pode ser elevada mesmo que o modelo foque apenas nas classes majoritárias, acertando sem realmente aprender com as features. Por sua vez, a ROC-AUC macro (bem como os valores individuais de ROC-AUC por classe, conforme a Figura 9) indica boa capacidade do classificador de distinguir as classes de TE's em termos de probabilidade, mas não garante que ele identifique corretamente as classes minoritárias.

Essa limitação fica evidente ao analisar as curvas de Precisão-Revocação (PR) e os valores de PR-AUC apresentados na Tabela 2: os valores mais baixos no conjunto de teste mostram que, apesar do alto ROC-AUC, o modelo comete muitos falsos positivos e falsos negativos ao classificar exemplos das classes menos representadas. As curvas de PR fornecem, portanto, uma visão mais realista do desempenho do classificador para cada classe.

Apesar dos valores mais altos de PR-AUC observados no conjunto de treino, esse desempenho não se mantém no conjunto de teste, indicando que o modelo ajustou-se excessivamente aos padrões específicos dos dados de treino (overfitting). Esse comportamento é comum em tarefas desbalanceadas, nas quais o modelo tende a memorizar exemplos das classes minoritárias em vez de aprender características generalizáveis.

De fato, de acordo com as curvas PR e a matriz de confusão (Figura 10), o modelo

apresenta dificuldades em identificar as classes minoritárias LINE e SINE, que possuem PR-AUC muito baixos e frequentemente são confundidas com classes mais expressivas, como LTR, TIR e MITE. O classificador também apresenta desempenho insatisfatório para Helitrons, acertando apenas um em quatro exemplos e classificando a maioria dos demais casos como LTR. Em contraste, o TE TIR, com PR-AUC ligeiramente superior (0,63), apresenta taxa de predição correta de 0,66. As maiores áreas sob as curvas PR correspondem às classes majoritárias LTR (0,86) e MITE (0,86), coerentes com as altas taxas de acerto observadas na matriz de confusão: LTRs são sempre classificados corretamente, enquanto MITE é identificado corretamente 72% das vezes. Além disso, essas duas classes nunca são confundidas entre si, evidenciando que o modelo consegue distinguir bem os elementos mais abundantes.

Em suma, embora as features extraídas tenham sua contribuição para o modelo de classificação, o desbalanceamento das classes exerce um efeito considerável sobre o desempenho, limitando a capacidade do classificador de identificar corretamente as classes menos representadas, o que é verificado na métrica PR-AUC macro = 0.4951 do conjunto de teste. Dessa forma, métricas globais como acurácia e ROC-AUC macro podem superestimar a qualidade do modelo, enquanto métricas como PR-AUC e análises por classe fornecem uma avaliação mais realista do comportamento do classificador.

4.2. Features consideradas

A análise da importância das features indica que a variável `length` é a mais determinante para o modelo, respondendo por cerca de 46% da importância total. Isso mostra que o comprimento das sequências desempenha um papel central na classificação dos elementos transponíveis. Em seguida, `ORF_maximum_ORF_length` destaca-se como a segunda feature mais importante, sugerindo que a extensão máxima dos ORFs contribui significativamente para a distinção das classes. `Shannon_k3_k3`, que mede a entropia da sequência, aparece logo após, indicando que a diversidade ou complexidade da sequência também auxilia na classificação.

Outras features relacionadas aos ORFs, como `ORF_cv_ORF_length`, `ORF_std_ORF_length` e `ORF_average_ORF_length`, apresentam contribuições menores, mas ainda relevantes, refletindo que características de variabilidade e média do ORF refinam o desempenho do modelo. As contagens de trinucleotídeos (`TNC_*`) possuem importância relativamente baixa individualmente, mas fornecem informações adicionais sobre padrões específicos da sequência que complementam as features principais.

Em resumo, o modelo depende principalmente de comprimento, propriedades dos ORFs e valores de entropia, com apoio de padrões de trinucleotídeos para ajustes finos na classificação.

Quanto à correlação entre as dez features mais importantes, observa-se que os maiores valores concentram-se entre os seis principais atributos (`length`, propriedades dos ORFs e `Shannon_k3_k3`), localizados no canto superior esquerdo da matriz normalizada. Nenhuma correlação ultrapassa 0,95, em conformidade com o pré-processamento que removeu features altamente redundantes.

5. Conclusão

Neste estudo, implementou-se um pipeline automatizado para a extração e classificação de Elementos Transponíveis (TEs) do genoma de *Zea mays*, integrando arquivos de anotação e sequências genômicas para gerar um conjunto de dados robusto. As sequências foram processadas com a ferramenta *MathFeature* para a extração de características estruturais e composicionais, e submetidas a um modelo de classificação baseado em Random Forest.

Os resultados indicam que o classificador apresenta bom desempenho para classes majoritárias, como LTR e MITE, com alta precisão e capacidade de distinção, mas com limitações para classes minoritárias (LINE, SINE e Helitron) evidenciado pela baixa PR-AUC, como esperado devido ao alto desbalanceamento de classes. A análise das features revelou que o comprimento das sequências, propriedades dos ORFs e a entropia de Shannon são os atributos mais relevantes para a classificação.

O estudo ressalta a importância do pré-processamento cuidadoso, incluindo a filtragem de sequências e seleção de features, para a obtenção de modelos mais robustos. O pipeline proposto é totalmente reprodutível e fornece uma base para estudos futuros, podendo ser aprimorado com técnicas de balanceamento de classes, seleção de features mais avançada ou integração de novas representações de sequências.

Em síntese, o trabalho demonstra o potencial de abordagens automatizadas e baseadas em descritores matemáticos para a análise de TEs em genomas complexos, contribuindo para a compreensão de padrões estruturais e funcionais desses elementos genômicos.

References

- Feng, Y. (2003). Plant mites: useful tools for plant genetics and genomics. *Genomics, Proteomics Bioinformatics*, 1(2):90–99.
- Li, R., Yao, J., Cai, S., Fu, Y., Lai, C., Zhu, X., and ... Li, Y. (2024). Genome-wide characterization and evolution analysis of miniature inverted-repeat transposable elements in barley (*Hordeum vulgare*). *Frontiers in Plant Science*, 15:Article 1474846.
- Mhiri, C., Borges, F., and Grandbastien, M.-A. (2022). Specificities and dynamics of transposable elements in land plants. *Biology*, 11(4):488.
- Stitzer, M. C., Anderson, S. N., Springer, N. M., and Ross-Ibarra, J. (2021). The genomic ecosystem of transposable elements in maize. *PLoS Genetics*, 17(10):e1009768.